十站点概念漂移的主驱动识别

2026 年 10 月 27 日实验纪要

本机当日跑完的结果

数据与表来自 `cursor/10site-cd-primary-driver-a248`

提交 `a3545e6`，太平洋时间 2026-10-27 02:10

太平洋时间 2026 年 10 月 27 日

摘要

今天在本仓库上跑完并落盘的实验，是一套十站点的概念漂移基准。协变量来自 ACS 2018 加州 person 文件上的两个 WhyShift 任务：收入是否超过五万美元，以及是否享有公共医疗保险。十个站点共用同一份经验分布 $P(X)$。预烧四个批次之后，从第 8 个批次起，五个站点写入彼此不同的概念漂移，四个站点保持真实标签，一个站点把标签换成公平硬币。

主分数 Δ_{cf} 是等样本量的 Brier 差，乘上本地模型相对抛硬币的技能，再在全样本和 X_1 的上下尾里取最大。在满强度、突然激活、线性规则作用于 X_1 中位数以上这一格上，Δ_{cf} 把五个结构化漂移站点全部排在干净站点和噪声站点之前。两个任务、四个种子的配对一致率都是 1.000，最差种子也是 1.000。按 Δ_{cf} 取出的前五个站点，就是这五个漂移站点。

协变量对照停在机会水平附近。边际标签总变差同样接近一半，因为结构化规则在被改写的行上对齐了基线正例率。噪声站点会抬高未加权的伪结果平方和、合并参考模型的 Brier 超额，以及联合 C2ST。技能门把这条假驱动拿掉。工作边界在弱改写和薄尾部：改写概率降到 0.4，或者线性规则只作用在工时的 0.9 分位以上，一致率落到 0.8 以下。

目录

1 当天跑完的实验 **1**

2 设计 **2**

3 分数 **3**

4 主格：谁排在干净站点前面 **3**

5 漂移有没有写进去 **6**

6 时间 **7**

7 类型与种植坐标 **8**

8 把十条站点收成一条支撑 **9**

9 强度、尾部和渐进激活 **12**

10 怎么读这些数 **13**

A 同日另一份记录：条件分布反事实 **14**

1 当天跑完的实验

全部计分都在 2026 年 10 月 27 日上午完成，下面的钟点是太平洋时间。主结果写在分支 `cursor/10site-cd-primary-driver-a248` 的提交 `a3545e6`（世界时 09:10，太平洋时间 02:10）。定稿表在 `experiments/primary_driver_10site/results/`。本纪要里的数字是从这些 CSV 重新汇总的，三位小数与仓库里的 `RESULTS.md` 一致；不一致的地方按代码和 CSV 更正，并在第 10 节写明。

表 1： 当天的运行清单。带星号的行没有进入定稿 CSV。

时间	运行	耗时	结果
01:53	合成烟雾，旧分数 *	2.8 秒	一致率 0.850。文件随后删除。
01:53	收入，种子 0，整窗 Δ_{cf}*	20 秒	漂移均值 0.110，干净 0.000，噪声 0.001。
01:55	合成烟雾，区域最大 *	2.0 秒	一致率 1.000。漂移均值 0.108。
01:55	收入，种子 0，区域最大	25 秒	漂移 0.288，干净 0.004，噪声 0.001。并入主套件。
01:56	`test_dgp`*	—	打印 `dgp invariants ok`。
01:56	主套件，`--seeds 4`	约 8 分钟	两个任务各四个全量重复，外加 $q \in \{0.5, 0.7\}$ 的敏感性格子。
02:06	收入，薄尾与弱强度	128 秒	$q \in \{0.8, 0.9\}$，三十六格，轻量打分器。
02:08	报告与五张图	—	`RESULTS.md`、`summary.json`、五张 PNG。

定稿的 `site_scores.csv` 有 770 行、25 个设计格。其中主格是两个任务、$\alpha = 1$、突然激活、$q = 0.5$、种子 0–3，带时间曲线、C2ST、概念组重要度和特征重要度。其余 23 格只在收入任务上、种子 0–2，用轻量随机森林，不计算 C2ST、概念组、特征重要度和时间曲线。$\alpha = 1$、突然激活、$q = 0.5$ 这一行没有用轻量打分器重跑，敏感度表里的这一格就是主套件的四个全量种子。

同日还看过 ACS Mobility（80,329 × 21）和 ACS Employment（378,817 × 16）的形状，没有计分。TableShift、HELOC、Voting、ACIC 2016 和 Taxi 没有跑。非线性规则的子组版本代码里有，这次没有用。

用户画布里另有一份当天上午写的「条件分布反事实」五层记录。那份记录的原始日志不在本仓库，附录 A 只转写已经写进画布的判定，不把它算进上面这 770 行。

2 设计

每个任务先丢掉非有限行。收入任务剩下 195,665 行、10 个官方协变量，正例率 0.411，标签是收入超过五万美元。X_1 是每周工时 WKHP，X_2 是学历 SCHL，X_3 是年龄 AGEP。公共医疗保险任务剩下 138,554 行、19 个官方协变量，正例率 0.369。X_1 是年龄，X_2 是学历，X_3 是个人收入 PINCP。

一次重复先在 16,000 行的分析样本上做缩尾标准化，再随机切成十个站点，每站 1,600 行。时间是合成的：16 个批次，每批 100 行。前四个批次所有站点都用真实基线标签。从 $t^* = 8$ 起：

- S0–S3 继续用基线标签。
- S4–S6 只在 X_1 高于分析样本分位数的行上，把标签改成站点自己的线性半空间。三个系数是 $(1, 0.35)$、$(0.25, 1)$、$(-0.85, 0.55)$。方向取与基线标签更不一致的一侧，再把被改写行的正例率拉回基线正例率。
- S7 在激活后的全部行上使用乘积 X_1X_2。S8 使用 $\sin(X_1) + X_3^2$。两条非线性规则同样做正例率匹配。
- S9 把激活后的标签换成 $\mathrm{Bernoulli}(0.5)$，故意不做正例率匹配。它破坏共识，不是主驱动。

α 是一条已激活的行真正被改写的概率。突然激活在 $t \geq 8$ 时权重为 1。渐进激活用四个批次把权重从 0 拉到 1，权重是 $\min\{1, (t - 8 + 1)/4\}$。主格取 $\alpha = 1$、突然激活、线性分位 $q = 0.5$。

工时在 40 小时有一个尖峰。全样本上，0.5 和 0.7 分位都落在 40，严格高于该分位的比例同为 0.226。所以 $q = 0.5$ 和 $q = 0.7$ 选中的是同一批人。这两列都跑过，数值逐格相同；正文的敏感度表只留 $q = 0.5$。0.8 分位是 45 小时，线性站点上被改写的比例大约 0.173；0.9 分位是 50 小时，大约 0.078。

3 分数

参考模型只用预烧窗口。每个站点在最近六个批次上做三折交叉拟合。主格的随机森林是 25 棵树、深度 8、叶节点最少 5 个样本、置换重复 3 次。轻量格是 20 棵树、深度 7、置换重复 2 次。

记 $\mu_{\mathrm{ref}}^{(n)}$ 为把参考模型压到与本地样本等量后的预测，μ_{loc} 为本地交叉拟合预测。技能是

$$\mathrm{skill} = \max\bigl\{2(\mathrm{AUC}_{\mathrm{loc}} - 1/2),\, 0\bigr\}.$$

三个区域是全样本，以及预烧期 X_1 的上尾和它的补集。区域只用协变量。主分数取三个区域里技能门控 Brier 差的最大者：

$$\Delta_{\mathrm{cf}} = \max_{r}\Bigl(\mathrm{Brier}\bigl(\mu_{\mathrm{ref}}^{(n)}, r\bigr) - \mathrm{Brier}\bigl(\mu_{\mathrm{loc}}, r\bigr)\Bigr) \times \mathrm{skill}.$$

`delta_cf_global` 只保留全样本那一项，用来看子组漂移被未改写的行稀释之后还剩多少。

τ^2 是同一对预测的均方差，对应伪结果分解里的概念项。不乘技能时，噪声站点也会很大。门控版本乘上同一个技能。等样本量 Brier 差本身不乘技能；合并参考模型用的是更大的参考样本，样本量差会留在分数里。

配对一致率是严格大于的比例。CD > clean 的分母是 $5 \times 4 = 20$ 对。设计目标是 Δ_{cf} 的这一一致率高于 0.8。Pareto 分数是秩的相反数，所以一致率仍然是「漂移站点排在前面」的比例。主格的八次全量重复带有时间曲线，秩用三条轴：Δ_{cf}、技能门控后的 τ^2，以及

$$\mathrm{time_jump} = \max_{t \geq t^*} \Delta_{\mathrm{cf}}(t) - \max_{t < t^*} \Delta_{\mathrm{cf}}(t).$$

敏感性格子没有曲线，秩只用前两条轴。仓库里的 `RESULTS.md` 只写了前两条，那一句对主格偏窄；本纪要按 `add_pareto` 更正。

4 主格：谁排在干净站点前面

表 2 和表 3 是主格的平均一致率，括号里是四个种子里的最小值。概念分数这一组里，Δ_{cf}、整窗 Δ_{cf}、两种 τ^2、等样本量 Brier 差和 Pareto 秩在两个任务上的五个对比都是 1.000。

表 2：主格概念分数的配对一致率。单元格是四个种子的平均，括号内是最差种子。主格：$\alpha = 1$，突然激活，$q = 0.5$。

任务	分数	CD>clean	CD>noise	线性 >clean	非线性 >clean	CD> 其余
收入	Δ_{cf}	1.000 (1.000)	1.000 (1.000)	1.000 (1.000)	1.000 (1.000)	1.000 (1.000)
收入	整窗 Δ_{cf}	1.000 (1.000)	1.000 (1.000)	1.000 (1.000)	1.000 (1.000)	1.000 (1.000)
收入	τ^2，技能门控	1.000 (1.000)	1.000 (1.000)	1.000 (1.000)	1.000 (1.000)	1.000 (1.000)
收入	τ^2，未加权	1.000 (1.000)	1.000 (1.000)	1.000 (1.000)	1.000 (1.000)	1.000 (1.000)
收入	等量 Brier 差	1.000 (1.000)	1.000 (1.000)	1.000 (1.000)	1.000 (1.000)	1.000 (1.000)
收入	合并参考 Brier 差	1.000 (1.000)	0.400 (0.400)	1.000 (1.000)	1.000 (1.000)	0.880 (0.880)
收入	Pareto 秩	1.000 (1.000)	1.000 (1.000)	1.000 (1.000)	1.000 (1.000)	1.000 (1.000)
收入	本地技能	0.938 (0.800)	1.000 (1.000)	1.000 (1.000)	0.844 (0.500)	0.950 (0.840)
医保	Δ_{cf}	1.000 (1.000)	1.000 (1.000)	1.000 (1.000)	1.000 (1.000)	1.000 (1.000)
医保	整窗 Δ_{cf}	1.000 (1.000)	1.000 (1.000)	1.000 (1.000)	1.000 (1.000)	1.000 (1.000)
医保	τ^2，技能门控	1.000 (1.000)	1.000 (1.000)	1.000 (1.000)	1.000 (1.000)	1.000 (1.000)
医保	τ^2，未加权	1.000 (1.000)	1.000 (1.000)	1.000 (1.000)	1.000 (1.000)	1.000 (1.000)
医保	等量 Brier 差	1.000 (1.000)	1.000 (1.000)	1.000 (1.000)	1.000 (1.000)	1.000 (1.000)
医保	合并参考 Brier 差	1.000 (1.000)	1.000 (1.000)	1.000 (1.000)	1.000 (1.000)	1.000 (1.000)
医保	Pareto 秩	1.000 (1.000)	1.000 (1.000)	1.000 (1.000)	1.000 (1.000)	1.000 (1.000)
医保	本地技能	1.000 (1.000)	1.000 (1.000)	1.000 (1.000)	1.000 (1.000)	1.000 (1.000)

表 3: 主格对照分数的配对一致率。括号内是最差种子。Domain AUC 和 MMD 只用协变量。标签总变差只用边际 Y。

任务	分数	CD>clean	CD>noise	线性 >clean	非线性 >clean	CD> 其余
收入	联合 C2ST	0.850 (0.800)	0.350 (0.200)	0.750 (0.667)	1.000 (1.000)	0.750 (0.680)
收入	C2ST 缺口	0.875 (0.700)	0.400 (0.400)	0.792 (0.500)	1.000 (1.000)	0.780 (0.640)
收入	标签总变差	0.500 (0.100)	0.050 (0.000)	0.500 (0.083)	0.500 (0.125)	0.410 (0.080)
收入	随机森林 domain AUC	0.487 (0.400)	0.500 (0.000)	0.521 (0.333)	0.438 (0.250)	0.490 (0.320)
收入	逻辑回归 domain AUC	0.300 (0.100)	0.450 (0.000)	0.271 (0.083)	0.344 (0.000)	0.330 (0.080)
收入	RBF MMD	0.412 (0.300)	0.500 (0.000)	0.375 (0.167)	0.469 (0.125)	0.430 (0.360)
医保	联合 C2ST	0.950 (0.850)	0.450 (0.200)	0.917 (0.750)	1.000 (1.000)	0.850 (0.720)
医保	C2ST 缺口	1.000 (1.000)	0.550 (0.200)	1.000 (1.000)	1.000 (1.000)	0.910 (0.840)
医保	标签总变差	0.613 (0.350)	0.000 (0.000)	0.604 (0.417)	0.625 (0.250)	0.490 (0.280)
医保	随机森林 domain AUC	0.438 (0.350)	0.200 (0.000)	0.396 (0.167)	0.500 (0.250)	0.390 (0.320)
医保	逻辑回归 domain AUC	0.350 (0.250)	0.100 (0.000)	0.375 (0.167)	0.312 (0.000)	0.300 (0.200)
医保	RBF MMD	0.600 (0.500)	0.200 (0.000)	0.562 (0.417)	0.656 (0.375)	0.520 (0.480)

收入任务上，合并参考模型的 Brier 差对噪声的一致率只有 0.400：噪声标签和一把很准的基线模型对不上，超额风险看起来像很强的漂移。等样本量再乘技能之后，这个假驱动消失，Δ_{cf} 对噪声的一致率回到 1.000。联合 C2ST 能把漂移和干净站点分开（收入 0.850，医保 0.950），同时把噪声站点排得更靠前。它检查的是联合分布变了，不检查新标签还能不能被 X 解释。

表 4：主格上各类站点的 Δ_{cf} 均值。每个数字是四个种子的站点平均。收入的干净、线性、噪声、非线性分别有 16、12、4、8 行，医保同样。

任务	类型	Δ_{cf}	整窗	上尾	τ^2 门控	技能	Pareto 秩
收入	干净	0.003	0.000	0.002	0.011	0.696	6.62
收入	线性	0.253	0.024	0.253	0.169	0.937	3.25
收入	噪声	0.001	0.000	0.000	0.001	0.009	6.75
收入	非线性	0.336	0.299	0.316	0.275	0.897	1.88
医保	干净	0.001	0.000	0.001	0.005	0.364	7.19
医保	线性	0.200	0.052	0.200	0.124	0.943	2.67
医保	噪声	0.003	0.002	0.003	0.004	0.089	6.50
医保	非线性	0.236	0.182	0.179	0.155	0.969	1.38

线性漂移几乎全部出现在 X_1 上尾：收入线性站点的整窗 Δ_{cf} 只有 0.024，上尾是 0.253，和区域最大后的主分数相同。非线性站点在整窗上已经有 0.299（收入）和 0.182（医保），因为规则写进了全部激活行。噪声站点的未加权 τ^2 在收入上是 0.096，乘上技能之后剩下 0.001。

表 5：四个种子各自的 Δ_{cf} 均值。漂移列是五个结构化站点的平均。

任务	种子	五个漂移站点	四个干净站点	噪声站点	线性 / 非线性
收入	0	0.288	0.004	0.001	0.234 / 0.368
收入	1	0.277	0.002	0.000	0.238 / 0.335
收入	2	0.278	0.005	0.000	0.260 / 0.305
收入	3	0.302	0.001	0.001	0.280 / 0.336
医保	0	0.218	0.003	0.002	0.203 / 0.241
医保	1	0.203	0.001	0.002	0.186 / 0.228
医保	2	0.219	0.000	0.009	0.206 / 0.238
医保	3	0.217	0.001	0.001	0.204 / 0.237

5 漂移有没有写进去

表 6 是主格上、激活之后的标签诊断。干净站点的翻转率是 0。噪声站点的翻转率接近 1/2，激活后正例率也接近 1/2，基线正例率仍在 0.36–0.41。结构化站点的激活后正例率被拉回基线：收入线性从基线 0.414 到激活后 0.400，非线性从 0.420 到 0.396。边际标签因此不能代替概念漂移，这和表 3 里标签总变差接近 0.5 是同一件事。

收入线性站点只改写大约 23% 的行，所以翻转率 0.131 低于医保线性的 0.259。医保的 X_1 是年龄，中位数以上大约一半样本。

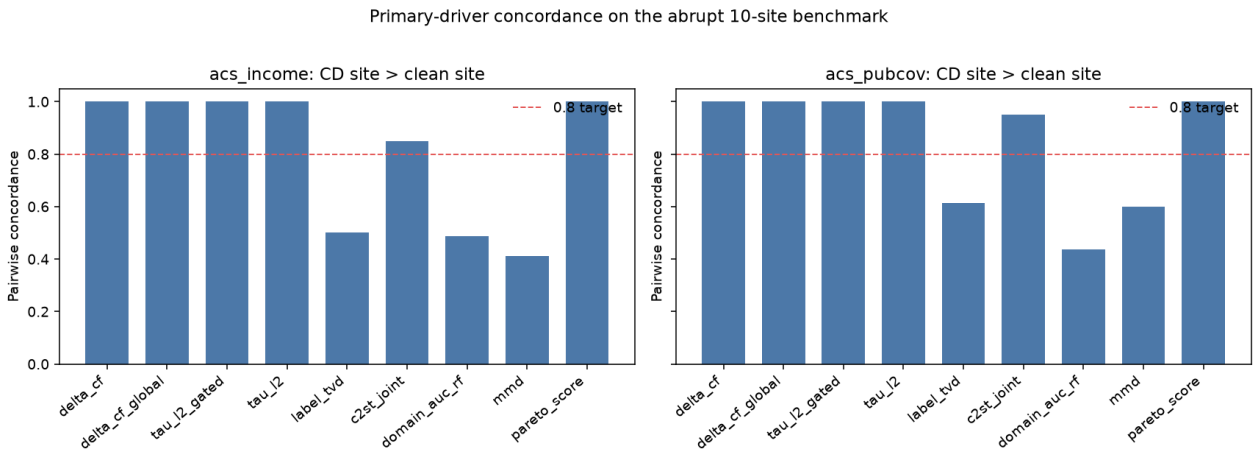


图 1： 主格上，各分数把概念漂移站点排在干净站点前面的比例。虚线是 0.8。来源：`concordance_summary.csv`，四个种子。

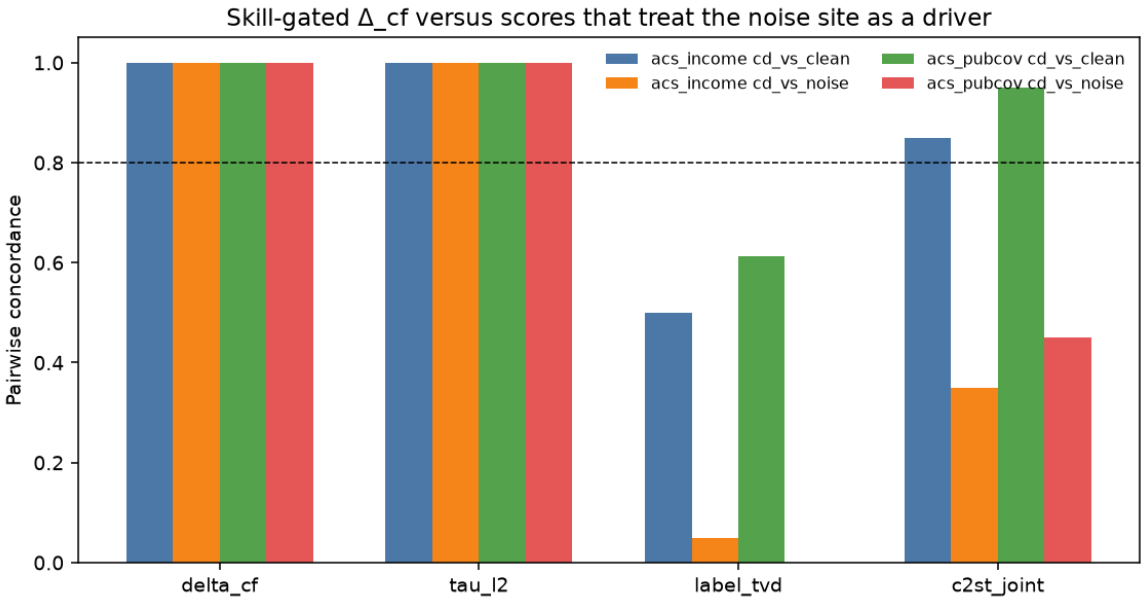


图 2： 概念漂移站点相对噪声站点的一致率。合并超额、标签总变差和联合 C2ST 会把随机标签当成驱动。技能门控后的 Δ_{cf} 保持 1.000。

6 时间

滑动窗口长度是 4。曲线的横轴是窗口末端批次，从 7 到 15。漂移在批次 8 打开，窗口要到批次 11 才完全落进漂移，分数也在那里饱和。表 7 是四类站点、四个种子的 Δ_{cf} 平均。

在线规则用每条曲线的前两个点做校准，阈值是校准最大值加 0.01，第一次越线的窗口末端就是估计时间。命中指估计值与 t^* 相差不超过 2。在线 MAE 只在越线的站点上平均，没越线的站点（$t_{\mathrm{online}} = -1$）不进分母。导数时间是一阶差分最大的窗口末端，它标的是分数爬升的位置，通常比起点晚一个窗口。

误报这一列在代码里只对干净站点有定义：干净站点一旦越线就记 1。线性、非线性和噪声的误报被写成 0，不是测出来的零。表 8 因此只对干净站点报告误报率，其余类型报告检测率。

非线性站点，以及医保的线性站点，命中率是 1。收入线性大约 0.83：十二个站点都越了线，有两个的越线位置超出 ± 2。收入干净站点的在线误报率是 0.375。阈值只比校准段最大值高 0.01，短

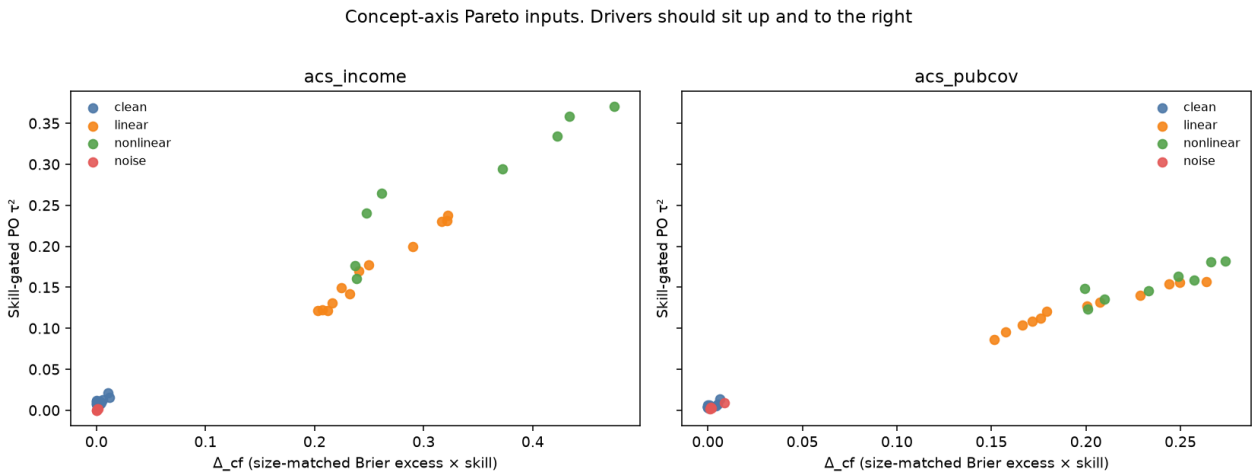


图 3： 主格站点在 Δ_{cf} 和技能门控 τ^2 上的位置。Pareto 秩还使用了第三条轴 time_jump，图上只画了前两条。

表 6： 主格的数据生成诊断。翻转率、规则与基线的一致率、激活后正例率、基线正例率，以及线性规则实际覆盖的行比例。

任务	类型	翻转率	与基线一致	激活后正例率	基线正例率	子组比例
收入	干净	0.000	1.000	0.406	0.406	0.226
收入	线性	0.131	0.427	0.400	0.414	0.230
收入	噪声	0.498	1.000	0.491	0.410	0.221
收入	非线性	0.555	0.436	0.396	0.420	0.225
医保	干净	0.000	1.000	0.369	0.367	0.494
医保	线性	0.259	0.476	0.378	0.372	0.492
医保	噪声	0.496	1.000	0.495	0.362	0.483
医保	非线性	0.492	0.506	0.371	0.374	0.490

窗口上的噪声会越线，越线的位置远离 t^*，所以命中率仍然只有 0.062。

7　类型与种植坐标

概念组事先指定为三组充分统计量：(X_1, X_2)、乘积 X_1X_2、$(\sin X_1,\, X_3^2)$。组重要度是该组交叉拟合 Brier 相对截距模型的下降。类型判定取重要度最大的组。`type_call_all` 用最近窗口的全部行；`type_call_sub` 只用 X_1 高于全局分位数的子组。准确率只在五个真实漂移站点上计算，每个种子五站。Top-5 精度是按 Δ_{cf} 取出的五个站点里真正是漂移站点的比例，八个主重复都是 1.000。

全样本上，乘积和正弦平方被对应的概念组认出来，线性站点只有一半。子组以外的标签仍是基线结果，加法模型会和基线结构混在一起。判定限制在 X_1 上尾之后，线性召回升到 0.917，正弦平方仍然是 1。乘积规则写在全部行上，上尾里的截断让线性拟合看起来也不差，召回降到 0.375。

种植支撑：线性和乘积是 $\{X_1, X_2\}$，正弦平方是 $\{X_1, X_3\}$。表 10 的 AUROC 是特征分数对这个 0/1 支撑的排序。`shift_vimp` 是概念间隙在条件置换该坐标后的下降。`delta_pred_vimp` 是最近窗口的预测型置换重要度减去预烧期的同一重要度。

表 7： 窗口末端批次上的平均 Δ_{cf}。$t^{*}=8$。

任务	类型	7	8	9	10	11	12	13	14	15
收入	干净	0.003	0.002	0.003	0.003	0.002	0.006	0.003	0.006	0.002
收入	线性	0.002	0.005	0.011	0.070	0.225	0.223	0.213	0.231	0.227
收入	非线性	0.002	0.005	0.022	0.099	0.330	0.321	0.309	0.340	0.310
收入	噪声	0.008	0.004	0.003	0.003	0.002	0.005	0.002	0.004	0.006
医保	干净	0.001	0.001	0.002	0.004	0.003	0.003	0.003	0.002	0.002
医保	线性	0.002	0.002	0.015	0.072	0.184	0.180	0.189	0.183	0.185
医保	非线性	0.001	0.002	0.015	0.060	0.173	0.178	0.185	0.173	0.171
医保	噪声	0.003	0.001	0.001	0.003	0.006	0.001	0.004	0.003	0.002

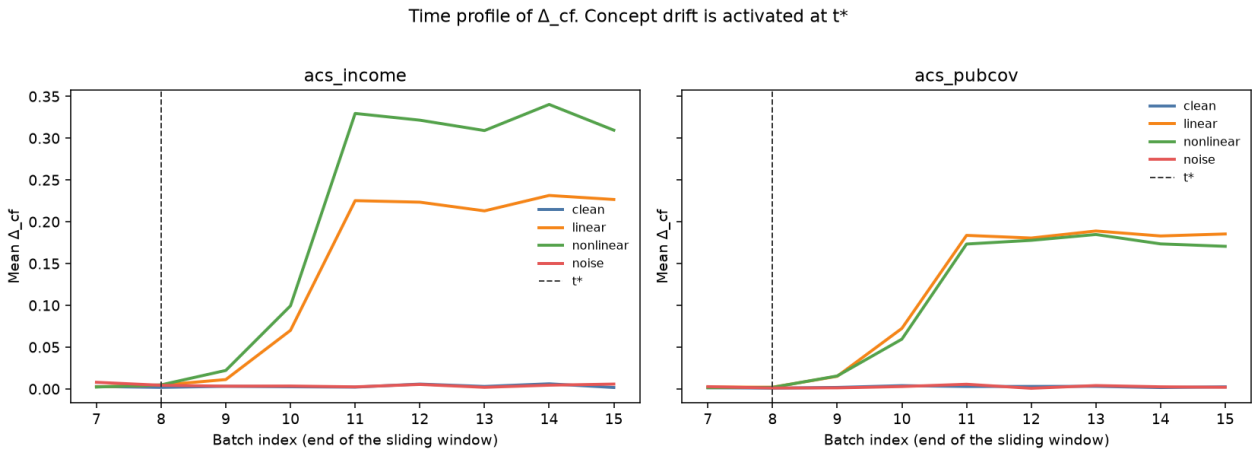


图 4： 平均 Δ_{cf} 对窗口末端批次。竖线是 $t^{*}=8$。干净站点和噪声站点贴着零。

8 把十条站点收成一条支撑

每个站点上传一条概念间隙重要度，先截断负值，再归一成单纯形。真值向量把每个漂移站点的种植坐标加一。Δ_{cf} 加权在干净站点和噪声站点接近零时，不会把它们送进聚合。IVW 用置换重复的方差，方差下界 10^{-4}。

收入上，这些种植坐标本来就会预测基线标签，所以干净站点的预测重要度也指向它们。均匀的概念间隙聚合 AUROC 是 0.869；用 Δ_{cf} 当站点权重之后是 0.917。医保上，均匀聚合已经是 0.995，Δ_{cf} 加权把它收到 1.000。均匀的 ℓ_1 和预测重要度在收入上更高（0.988），因为它们用的是基线就能看见的预测结构，不是概念间隙。

留一站点的影响度定义为全体均匀聚合与去掉该站点之后的 Spearman 距离，$1-\rho$。表 12 里四类站点都很小，而且干净站点并不比较漂移站点更小。站点级的 Δ_{cf} 能指出主驱动；均匀重要度聚合的留一影响度不能。

表 8： 时间定位。命中率的分母是该类的全部站点。在线 MAE 的分母写在括号里，是实际越线的站点数。

任务	类型	命中率	干净误报 / 检测率	在线 MAE	导数 MAE
收入	干净	0.062	误报 0.375	4.167 (6/16)	4.062
收入	线性	0.833	检测 12/12	1.917 (12/12)	2.833
收入	噪声	0.250	检测 2/4	4.000 (2/4)	3.250
收入	非线性	1.000	检测 8/8	1.625 (8/8)	3.000
医保	干净	0.062	误报 0.125	3.000 (2/16)	3.875
医保	线性	1.000	检测 12/12	1.417 (12/12)	3.000
医保	噪声	0.000	检测 1/4	3.000 (1/4)	4.000
医保	非线性	1.000	检测 8/8	1.500 (8/8)	3.000

表 9： 五个漂移站点上的类型准确率，以及按机制合并两个任务后的召回。线性有 24 个站点–种子，两种非线性机制各有 8 个。

判定	范围	准确率或召回	Top-5 精度
全样本	收入，五站	0.700	1.000
全样本	医保，五站	0.700	1.000
X_1 上尾	收入，五站	0.750	1.000
X_1 上尾	医保，五站	0.900	1.000
全样本	线性半空间	0.500	—
全样本	乘积	1.000	—
全样本	$\sin(X_1) + X_3^2$	1.000	—
X_1 上尾	线性半空间	0.917	—
X_1 上尾	乘积	0.375	—
X_1 上尾	$\sin(X_1) + X_3^2$	1.000	—

表 10： 特征支撑的 AUROC。收入每个站点 10 个特征，医保 19 个。线性 $n = 12$ 个站点–种子，非线性 $n = 8$。

任务	类型	预测重要度之差	ℓ_1 系数	预测重要度	概念间隙重要度
收入	线性	0.651	0.786	0.927	0.906
收入	非线性	1.000	0.930	1.000	0.789
医保	线性	0.944	0.841	0.995	0.953
医保	非线性	0.985	0.879	1.000	0.985

表 11： 聚合器对种植支撑的恢复。四个种子的平均。$P@K$ 的 K 等于种植坐标的个数。

任务	聚合器	AUROC	$P@K$	Spearman
收入	Δ_{cf} 加权的概念间隙	0.917	0.750	0.697
收入	逆方差加权	0.869	0.667	0.597
收入	中位数	0.869	0.667	0.608
收入	只用主驱动站点	0.893	0.667	0.664
收入	均匀，预测重要度之差	0.869	0.833	0.600
收入	均匀，ℓ_1 系数	0.988	0.917	0.798
收入	均匀，预测重要度	0.988	0.917	0.798
收入	均匀，概念间隙	0.869	0.667	0.597
收入	均匀，去掉噪声站点	0.869	0.667	0.589
医保	Δ_{cf} 加权的概念间隙	1.000	1.000	0.634
医保	逆方差加权	0.995	0.917	0.629
医保	中位数	0.984	0.833	0.615
医保	只用主驱动站点	0.995	0.917	0.630
医保	均匀，预测重要度之差	0.875	0.833	0.494
医保	均匀，ℓ_1 系数	0.927	0.667	0.552
医保	均匀，预测重要度	0.990	0.917	0.623
医保	均匀，概念间隙	0.995	0.917	0.629
医保	均匀，去掉噪声站点	1.000	1.000	0.635

表 12： 留一站点影响度 $1-\mathrm{Spearman}$。收入干净 $n=16$，线性 $n=12$，噪声 $n=4$，非线性 $n=8$；医保同样。

任务	干净	线性	噪声	非线性
收入	0.033	0.013	0.018	0.021
医保	0.008	0.006	0.006	0.005

9 强度、尾部和渐进激活

这一节只在收入任务上做。除主格外，每个格子是三个种子的轻量打分器。表 13 的一致率是 Δ_{cf} 的 CD $>$ clean。整窗列是同一对比下的 `delta_cf_global`。$q = 0.7$ 与 $q = 0.5$ 数值相同，表中省略；两列都在 CSV 里。

表 13: 收入任务上 Δ_{cf} 的一致率如何随强度、激活方式和线性尾部变化。括号内是最差种子。主格一行是四个全量种子，其余是三个轻量种子。

α	q	激活	平均一致率	最差种子	整窗一致率
0.4	0.5	突然	0.783	0.650	0.433
0.4	0.5	渐进	0.750	0.650	0.467
0.4	0.8	突然	0.617	0.450	0.550
0.4	0.8	渐进	0.600	0.450	0.617
0.4	0.9	突然	0.550	0.450	0.567
0.4	0.9	渐进	0.550	0.450	0.567
0.7	0.5	突然	1.000	1.000	0.933
0.7	0.5	渐进	1.000	1.000	1.000
0.7	0.8	突然	0.967	0.950	0.683
0.7	0.8	渐进	0.950	0.900	0.717
0.7	0.9	突然	0.817	0.750	0.567
0.7	0.9	渐进	0.683	0.500	0.500
1.0	0.5	突然	1.000	1.000	1.000
1.0	0.5	渐进	1.000	1.000	1.000
1.0	0.8	突然	1.000	1.000	1.000
1.0	0.8	渐进	1.000	1.000	1.000
1.0	0.9	突然	0.850	0.750	0.700
1.0	0.9	渐进	0.867	0.800	0.700

0.8 这条线在三处被踩破。$\alpha = 0.4$ 时，即使尾部仍有 23% 的行，区域最大的一致率是 0.783（突然）和 0.750（渐进），最差种子 0.650。$q = 0.9$ 时，满强度的突然激活也只有 0.850，最差种子 0.750；$\alpha = 0.7$ 的渐进激活掉到 0.683。$\alpha \geq 0.7$ 且尾部不少于 0.8 分位所覆盖的大约 17% 时，平均一致率保持在 0.95 以上。

整窗分数在弱改写上更早失败。$q = 0.5$、$\alpha = 0.4$ 时，区域最大还有 0.783 / 0.750，整窗只剩 0.433 / 0.467。仓库笔记里写的「掉到 0.45 左右」指的就是这一对，精确值是这两格。

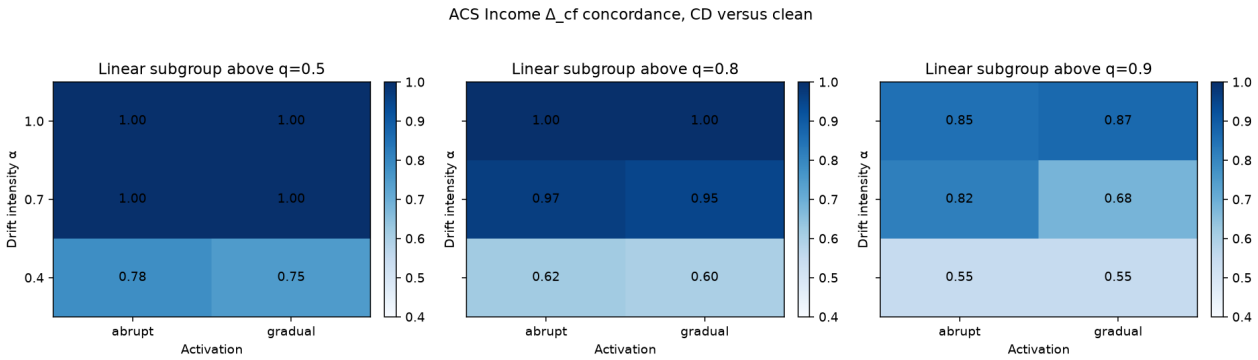


图 5： 收入任务、线性子组之上，Δ_{cf} 的 CD > clean 一致率。颜色是三个或四个种子的平均。$q = 0.7$ 与 $q = 0.5$ 重合，图中按分位分开画。

10　怎么读这些数

满强度、突然激活、中位数尾部这一格上，Δ_{cf} 完成了它被要求做的排序：五个结构化漂移站点全部在四个干净站点和一个噪声站点之前，两个任务、四个种子、最差种子都是 1。Pareto 秩同样是 1。Top-5 精度是 1。

这个分离来自概念项，不来自协变量臂。随机森林 domain AUC 和 MMD 的一致率落在 0.4–0.6。逻辑回归的 domain AUC 更低，收入上 CD > clean 只有 0.300。站点共享 $P(X)$，这两条臂应当接近一半，结果也是这样。

噪声站点是另一条失败模式。收入上，合并参考 Brier 差对噪声的一致率是 0.400，标签总变差是 0.050，联合 C2ST 是 0.350。未加权 τ^2 在主格上仍把噪声排在干净站点后面，是因为干净站点的 τ^2 更小（0.015 对噪声的 0.096 仍小于漂移站点的 0.181 和 0.313）；技能门把噪声的 τ^2 从 0.096 收到 0.001，和 Δ_{cf} 的 0.001 对齐。等样本量 Brier 差在主格上也是 1.000。技能门在这套满强度格子里是保险，在噪声的本地 AUC 靠近 0.5 时才会改排序。收入的本地技能单独使用时，CD > clean 是 0.938，最差种子 0.800：非线性站点里有一把技能只有 0.678 的站点，单靠 AUC 会把它排到部分干净站点后面。

时间上，曲线的形状和窗口长度一致：批次 8 打开，批次 11 饱和。在线命中对非线性和医保线性是 1，收入线性是 0.833。收入干净站点 0.375 的越线率说明 0.01 这个门槛对短窗口偏松；越线位置的 MAE 是 4.17 个批次，离 t^* 远。导数法的误差大约一个窗口长度。

类型字典是事先指定的。全样本召回把线性站点漏掉一半；收到 X_1 上尾之后，线性召回 0.917，乘积召回 0.375。两种判定不能同时用在所有机制上。特征支撑上，预测型置换重要度和概念间隙置换重要度都能把种植坐标排到前面。留一站点的秩影响在所有类型上都很小，不能代替站点级 Δ_{cf}。

有四件事先写明的读数限制。

1. 主格 Pareto 用了 Δ_{cf}、门控 τ^2 和 time_jump 三条轴。敏感性格子没有曲线，只用前两条。`RESULTS.md` 里「两条轴」只对后者成立。

2. 误报率只对干净站点有定义。其他类型在 `localize` 里被写成 0。

3. 在线 MAE 丢掉了没有越线的站点。表 8 写了分母。

4. $q = 0.5$ 与 $q = 0.7$ 在工时上是同一次实验。敏感度表不把它们算成两次独立证据。轻量格的 C2ST 列在打分器里被填成 0.5，那些格子的 C2ST 一致率是 0，不是测量，本纪要不报。

A　同日另一份记录：条件分布反事实

这一节转写当天 01:53（太平洋时间）写好的画布《条件分布反事实：四张面板的五层证伪》。原始扫描不在本仓库，下面的数没有在这台检出上重算。分数是观测分布和反事实预测分布的 MMD，除以无干预基线。阈值在跑实验之前写死。画布的结论是：没有一张面板达到可以拿去决策的等级。

表 14：五层判定，转自当天画布。通过线：L1 至少三种构造过线；L2 的安慰剂、峰值和门控都要过；L3 的 PIT、Wasserstein、HSIC 都要过；L4 至少三个代理同向；L5 的变异系数和 E-value 都要过。

面板	MVP	L1	L2	L3	L4	L5	可信度
长记忆模拟，峰值在第 10 天	进入	通过	未过	未过	通过	未过	低
短记忆模拟，峰值在第 1 天	进入	通过	通过	未过	通过	未过	低
北京多站点 PM2.5，2014–2017	停止	—	—	—	—	—	停止
美国各州疫情，2020-03 至 2021-06	继续	假设未支持	未过	未过	不确定	未过	低

长记忆面板的归一化 MMD 在假设滞后 1 到 15 上是 $0.10, 1.84, 0.22, 2.71, 4.59, 2.63, 45.5, 197, 224, 206, 0.17, 0.31, 0.39, 1.68, 10.5$。声明的真值是第 10 天（206×），扫描最大值在第 9 天（224×），差这一天，时间定位未过。第 15 天仍有 10.5×，安慰剂未过。短记忆的峰值在第 1 天，2.10×，其余滞后都低于 2，时间定位通过。美国南部相对东北部的十条滞后贴着 1，第 10 天是 1.00×，扫描最大值在第 1 天（1.43×）。

表 15：模拟面板的构造、校准与敏感性，转自当天画布。

项目	长记忆	短记忆
剂量–反应	一致率 0.90，Spearman 0.90	三种构造通过；时间距离 Spearman -0.685
时间距离	Spearman 0.16，与峰值假设不符	未到 -0.7，这一组失败
重叠度	一致率 0.83，Spearman 0.80	通过
外生隔离	效应量 -2.51，$p = 0.034$	通过
Wasserstein / 上限	0.082 / 0.095	0.078 / 0.093
HSIC 比值	0.87	0.86
PIT	四维都拒绝均匀	第 3 维 $p = 5 \times 10^{-5}$
核宽变异系数（线 0.20）	0.71	0.25
架构变异系数（线 0.30）	0.23	0.00
E-value（线 2）	19.9	32.9

北京，东四看古城、滞后 10 天：五段异常的排序一致率 0.30，Spearman -0.60，主查询倍数 0.30。协议在这里停止，没有训练 DDPM。美国疫情的业务窗口里南部确实异常（$z = 2.49$），但这条 10 天的跨区反事实没有解释它；观测 PIT 和 Wasserstein 都失败，所以「没有超过基线」本身也不可信。